

RDFスキーマ推論規則を対象とした 大規模言語モデルの推論能力の段階的評価

細川泰智¹, チャクラボルティ シュデシナ¹, 森田武史^{1,2}
¹青山学院大学, ²産業技術総合研究所



背景・動機

- LLM は自然言語処理タスクで高い性能を示すが、論理推論は依然として困難である
- LLM は明示的な論理推論ではなく、事前学習で得た知識に依存する傾向がある [3]
- 既存の RDFスキーマ (RDFS) 推論評価 [1] は体系性に欠け、単純な規則のみを対象としていた
- 反実仮想を用いた手法 [2,3] は有望だが、RDFS 推論への適用は限定的である
- 本研究では、RDFS 推論規則に基づく評価手法を提案し、実世界知識データセットと RDFS に特化した反実仮想知識データセットを用いて、複数規則の適用能力と規則選択能力を定量的に評価する

提案手法

概要

- 推論規則 6 種 → 推論パターン 19 種 (1+2+3 規則)
- データセット 3 種 (実世界知識 / 反実仮想知識 8 種 / ランダム記号)
- タスクレベル 6 段階 (Lv1〜3, Lv1i〜3i) / 指標：適合率・再現率・F1

RDFS推論規則と推論パターン

規則数	推論パターン
1	rdfs2, rdfs3, rdfs5, rdfs7, rdfs9, rdfs11
2	rdfs2_3, rdfs2_7, rdfs2_9, rdfs3_7, rdfs3_9, rdfs5_7, rdfs9_11
3	rdfs2_3_7, rdfs2_3_9, rdfs2_5_7, rdfs2_9_11, rdfs3_5_7, rdfs3_9_11

規則	前提	結論
rdfs2	<i, rdfs:domain, X>, <a, i, b>	<a, rdf:type, X>
rdfs3	<i, rdfs:range, X>, <a, i, b>	<b, rdf:type, X>
rdfs5	<i, rdfs:subPropertyOf, j>, <j, rdfs:subPropertyOf, k>	<i, rdfs:subPropertyOf, k>
rdfs7	<i, rdfs:subPropertyOf, j>, <a, i, b>	<a, j, b>
rdfs9	<X, rdfs:subClassOf, Y>, <a, rdf:type, X>	<a, rdf:type, Y>
rdfs11	<X, rdfs:subClassOf, Y>, <Y, rdfs:subClassOf, Z>	<X, rdfs:subClassOf, Z>

データセット

実世界知識 (RK) : DBpedia、Wikidata 等から構築
反実仮想知識 (S, NA/NR, SNA/SNR, GS, GSC, RND) : RK を改変
ランダム記号列 (NS) : 8 文字英数ランダム文字列で構築

反実仮想	構築方法
S	主語/述語、定義域/値域の入れ替え、階層関係のシャッフル
NA/NR	クラス・プロパティに「not」を接頭辞として付加 (NA: 全て / NR: ランダム)
SNA/SNR	S と NA/NR の組み合わせ
GS	全リソースをシャッフル
GSC	GS の各リソース名を配置先のタイプ本来の命名規則に変換
RND	リソースタイプ別に DBpedia からランダムに語彙を割当 [3]

フィールド	内容
前提知識	<birthPlace, rdfs:domain, Animal>, <Cam_Woods, birthPlace, Montreal>
期待される出力	<Cam_Woods, rdf:type, Animal>

タスクレベル

Lv1 : 単一の合成規則を適用 (例: rdfs2_3_7)
Lv2 : 与えられた個別の規則をすべて適用 (例: rdfs2、rdfs3、rdfs7)
Lv3 : 6 つの規則の集合から関連する規則を選択して適用
Lv1i / Lv2i / Lv3i : 規則定義を提示せず、規則名のみを与える

規則名	前提	結論
rdfs2_3_7	<i, rdfs:domain, X>, <i, rdfs:range, Y>, <i, rdfs:subPropertyOf, j>, <a, i, b>	<a, rdf:type, X>, <b, rdf:type, Y>, <a, j, b>

評価指標

- マッチング手法: 文字列類似度 (トリプル) 、完全一致 (規則)
- 指標: 適合率、再現率、F1 スコア

評価実験

規則適用能力 (規則数・タスクレベル・LLM 別の平均 F1 スコア)

規則数	タスクレベル	LLM	データセット					
			RK	SNA	GS	GSC	RND	NS
1	Lv1	GPT-4o mini	0.89	0.88	0.66	0.77	0.87	0.86
		GPT-4o	0.95	0.95	0.88	0.91	0.94	0.97
1	Lv3	GPT-4o mini	0.70	0.71	0.49	0.56	0.65	0.77
		GPT-4o	0.94	0.93	0.83	0.91	0.91	0.91
3	Lv2	GPT-4o mini	0.72	0.67	0.40	0.49	0.68	0.63
		GPT-4o	0.94	0.91	0.79	0.88	0.94	0.96
3	Lv3	GPT-4o mini	0.64	0.56	0.30	0.38	0.58	0.56
		GPT-4o	0.89	0.86	0.71	0.82	0.88	0.88

規則選択能力 (規則数・LLM 別の平均 F1 スコア)

規則数	LLM	データセット					
		RK	SNA	GS	GSC	RND	NS
1	GPT-4o mini	0.84	0.85	0.76	0.77	0.85	0.80
	GPT-4o	0.98	1.00	0.98	0.99	1.00	0.99
2	GPT-4o mini	0.89	0.90	0.81	0.82	0.95	0.96
	GPT-4o	0.99	0.99	0.89	0.91	0.99	1.00
3	GPT-4o mini	0.82	0.82	0.84	0.85	0.87	0.91
	GPT-4o	0.96	0.96	0.93	0.96	0.97	0.98

考察

語彙・表記の手がかりへの依存

- GS で性能低下、GSC で回復
- ▶ 命名パターンを推論の手がかりとして利用している
- GPT-4o は GPT-4o mini より依存度が低い

単純タスクでの規則の過剰適用

- GPT-4o mini は 1 規則タスクで不要な規則を適用
- GPT-4o はタスク制約をより忠実に守る

規則定義の重要性

- 規則名のみを提示した条件では両モデルとも大幅な精度低下
- 規則の詳細な定義情報が推論に不可欠

まとめ

- LLM の RDFS 推論能力を段階的に評価する手法を提案した
- LLM は厳密な論理推論ではなく語彙・表記の手がかりに依存している
- モデル規模の拡大により、より論理的な推論挙動が見られる
- 知識補完は不完全な知識グラフに対して有用である

現在の研究

本研究の発展として RDFS-LLM-Bench を構築

- 推論能力・規則選択能力・頑健性を測る 7 つの統合指標を提案
- 推論モデルと非推論モデルを比較評価
- 推論モデルは反実仮想条件下でも高い頑健性を維持
- 推論トレースを用いて推論モデルの頑健性を解析
- 全コンポーネントを GitHub・Zenodo で公開

OS-37 生成 AI とナレッジグラフで口頭発表予定 (詳細は左下の二次元コードより)

謝辞・参考文献

本研究は JSPS 科研費 (23K11221、25K03232) および NEDO (JPNP20006、JPNP25006) の支援を受けたものである。

参考文献:

- [1] Wu et al. (2023). "Do PLMs Know and Understand Ontological Knowledge?" ACL
[2] Ozeki et al. (2024). "NeuBAROCO: A Japanese Dataset for Evaluation of Syllogistic Reasoning Ability of Language Models" ANLP
[3] Morishita et al. (2024). "JFLD: A Japanese Benchmark for Deductive Reasoning Based on Formal Logic" LREC-COLING



← ポスターPDF・論文・研究詳細はこちら

関連発表: OS-37 生成 AI とナレッジグラフ
- [5G3-OS-37b-02] RDFS-LLM-Bench: 大規模言語モデルによる RDFスキーマ推論の多段階評価ベンチマークの提案
- 2026年6月12日 (金) 14:15~14:30 会場: G会場 (メインホールA)