

RDFS-LLM-Bench: 大規模言語モデルによる RDF スキーマ推論の多段階評価ベンチマークの提案

RDFS-LLM-Bench: A Multi-Level Benchmark for Evaluating RDF Schema Inference in Large Language Models

細川泰智^{*1}
Taichi Hosokawa

チャクラボルティ シュデシナ^{*1}
Sudesna Chakraborty

森田武史^{*1*2}
Takeshi Morita

^{*1} 青山学院大学

^{*1}Aoyama Gakuin University

^{*2} 産業技術総合研究所

^{*2}National Institute of Advanced Industrial Science and Technology

Large language models (LLMs) have achieved strong performance in various tasks, but they struggle with logical inference and often rely on pre-trained knowledge for reasoning. We propose a benchmark for assessing LLMs' logical inference abilities using RDF Schema entailment rules, comprising three dataset types: real-world knowledge data, counterfactual knowledge data, and random symbolic data, along with a multi-level evaluation framework measuring rule selection and application capabilities. Experiments using commercial and open-weight LLMs reveal that LLMs demonstrate high performance on random symbolic data, yet rely on linguistic cues such as naming conventions in vocabulary data, but fail to separate structural inference from inference based on these cues on counterfactual data, leading to performance decline. We also observed a tendency to supplement information with pre-trained knowledge, which may be advantageous where data is incomplete. These findings demonstrate the necessity of considering the potentials and limitations when leveraging LLMs in Semantic Web applications.

1. はじめに

近年、自然言語処理 (Natural Language Processing, NLP) の分野において、大規模言語モデル (Large Language Model, LLM) は広範な課題解決能力を示している。一方で、論理推論能力については依然として課題が指摘されており [Huang 23], [Morishita 24] は、LLM が明示的な論理推論ではなく、事前学習知識に依存して問題を解決する傾向を示している。

このような課題を受けて、[Ozeki 24] および [Morishita 24] では、現実とは異なる前提条件を与える反実仮想 (信念相反) 設定の下で、LLM が事前知識に依存せず論理的推論を行えるかを評価している。

一方、セマンティック Web 分野においては、オントロジーが知識を体系化する枠組みとして重要な役割を果たしている。Wu et al. [Wu 23] は、RDF スキーマ (Resource Description Framework Schema, RDFS) 推論規則に基づき、LLM によるオントロジーの記憶および理解と、推論への活用可能性を調査した。しかし、推論能力の評価はマスク言語モデリングによる自然言語の穴埋めタスクとして行われており、セマンティック Web において実際に用いられる Web オントロジー言語を直接対象とした推論評価とは異なる。また、推論は単一の RDFS 推論規則に基づくものに限られており、セマンティック Web における実用的な推論を十分に反映した評価とは言い難い。

そこで本研究では、RDFS 推論規則を対象として、LLM の論理推論能力を評価する新たなベンチマークを提案する。本ベンチマークでは、実世界知識データに加え、体系的に構築した反実仮想知識データおよびランダム記号列データを用いて、語彙や表記の特徴が推論に与える影響を構造的推論能力と切り離して評価可能な設計とする。また、複数の RDFS 推論規則を組み合わせ、より複雑な推論能力を評価する。さらに、推論規則の提示方法に段階を設け、規則の適用能力および選択能力を多角的に分析する。評価には、RDFS 語彙を含む RDF トリ

プルの入出力に基づく定量的評価手法を用いる。

2. 関連研究

[Wu 23] は、RDFS 推論規則を基盤として、事前学習済み言語モデル (Pre-trained Language Models, PLMs) によるオントロジーの保持・解釈と推論への活用可能性を調査した。DBpedia および Wikidata から取得したデータを対象として、rdfs2, rdfs3, rdfs5, rdfs7, rdfs9, rdfs11 の六つの RDFS 推論規則に基づく推論タスクを評価した。推論タスクはマスク言語モデリングによる自然言語の穴埋めタスクとして評価され、PLMs が一定程度のオントロジー知識を記憶していることが示されたが、定義域・値域制約や階層関係の理解に課題があることも明らかになった。

[Ozeki 24] は、NeuBAROCO データセットを用いて三段論法における LLM の推論能力を検証した。認知科学で広く研究されている推論バイアス、特に信念相反と Conversion error に着目した評価を行い、GPT-4 が信念相反や Conversion error を含む問題で正解率が低下することを示した。

[Morishita 24] は、日本語に特化した論理推論ベンチマーク JFLD を提案し、公理系による多段階推論を中心とした推論タスクを評価した。LLM の純粋な推論能力を評価するため反実仮想的アプローチが採用され、演繹規則の定数や述語に Multilingual WordNet からランダムに選択した語彙を割り当てた場合の推論能力が評価された。

これらの先行研究に対し、本研究では以下の点で新規性を有する。[Wu 23] がマスク言語モデリングによる自然言語ベースの評価を行ったのに対し、本研究は RDFS 語彙を含む RDF トリプルを直接入出力する形式で評価を行う。また、単一規則の適用のみならず、複数規則の組み合わせによる推論および規則選択能力を評価対象とする。さらに、RDFS 推論に特化した複数の反実仮想設定を用意し、様々な観点から LLM の推論能力を評価可能な枠組みを提供する。

なお、本研究は著者らの先行研究 [細川 25] を拡張・ベンチマーク化したものであり、統合指標の導入、データセットの追加、およびオープンウェイト LLM を含む評価対象 LLM の拡

連絡先: 森田武史, 青山学院大学理工学部, 〒 252-5258
神奈川県相模原市中央区淵野辺 5-10-1, E-mail:
morita@it.aoyama.ac.jp

表 1: 評価対象の RDFS 推論規則一覧

規則名	前提	結論
rdfs2	<i, rdfs:domain, X> <a, i, b>	<a, rdf:type, X>
rdfs3	<i, rdfs:range, X> <a, i, b>	<b, rdf:type, X>
rdfs5	<i, rdfs:subPropertyOf, j> <j, rdfs:subPropertyOf, k>	<i, rdfs:subPropertyOf, k>
rdfs7	<i, rdfs:subPropertyOf, j> <a, i, b>	<a, j, b>
rdfs9	<X, rdfs:subClassOf, Y> <a, rdf:type, X>	<a, rdf:type, Y>
rdfs11	<X, rdfs:subClassOf, Y> <Y, rdfs:subClassOf, Z>	<X, rdfs:subClassOf, Z>

充を行った。また、規則提示条件を追加し、アブレーション分析を実施した。

3. 提案手法

3.1 概要

本ベンチマークは、六つの RDFS 推論規則を対象として、一つから三つの規則を組み合わせた 19 種類の推論タスクを設定する。各タスクに対して、実世界知識、反実仮想知識、ランダム記号列の 7 種類のデータセットを用意する。評価タスクは Lv1~3 系の 3 段階で構成され、各段階に対して規則提示方法の異なる 3 条件（無印条件, i 条件, a 条件）を設定する。また、LLM 間の性能比較のために七つの統合指標を定義する。

3.2 評価対象の RDFS 推論規則

RDFS 推論規則のうち、rdfs2（定義域による型推論）、rdfs3（値域による型推論）、rdfs5（プロパティの推移性）、rdfs7（プロパティの継承）、rdfs9（クラスの継承）、rdfs11（クラスの推移性）の六つを評価対象とする（表 1）。これらの規則は [Wu 23] で評価対象とされており、実用的な推論能力の評価に適している。選定しなかった規則は、基本的な概念や定義に関する自明な規則であり、推論能力の評価には不適切と判断した。

3.3 推論タスクの作成

本ベンチマークでは、一つから三つの規則を用いた推論を評価する。具体的には、1-rule として 6 種類（rdfs2, rdfs3, rdfs5, rdfs7, rdfs9, rdfs11）、2-rule として 7 種類（rdfs2+3, rdfs2+7, rdfs2+9, rdfs3+7, rdfs3+9, rdfs5+7, rdfs9+11）、3-rule として 6 種類（rdfs2+3+7, rdfs2+3+9, rdfs2+5+7, rdfs2+9+11, rdfs3+5+7, rdfs3+9+11）の計 19 種類の推論を評価対象とする。選定した規則の組み合わせについて、各規則の前提トリプルを結合することで推論タスクの前提を定義する。そして、RDFS 推論器（Apache Jena Inference API）を用いて結論トリプルを導出する。作成した前提と結論の対を拡張 RDFS 推論規則として定義し、具体的な語彙を割り当てることで各推論タスクに対応するデータセットを作成する。拡張 RDFS 推論規則の詳細は [細川 25] に示されている。

3.4 データセット設計

LLM の構造的推論能力と、語彙や表記の特徴の推論への影響を評価するため、意味的データの有無、語彙とリソースタイプの対応関係、命名規則を独立に操作可能なデータセットを設計する。

本ベンチマークのデータセットは、大きく意味的データセットおよび非意味的データセットに分類される。意味的データセットは、実世界知識データセット（RK）と 4 種類の反実仮

表 2: 実世界知識データセットの例 (rdfs2)

項目	内容
規則	if <i, rdfs:domain, X> and <a, i, b> then <a, rdf:type, X>
前提	<birthPlace, rdfs:domain, Animal> <Cam.Woods, birthPlace, Montreal>
結論	<Cam.Woods, rdf:type, Animal>

想知識データセット（LS, RVA, GS, GSC）から構成される。非意味的データセットは、2 種類のランダム記号列データセット（NS, NSC）から構成される。

3.4.1 実世界知識データセット

実世界知識データセットは、DBpedia, Wikidata, および Linked Open Vocabularies の SPARQL エンドポイントから取得したトリプルを用いて構築され、現実知識に基づく推論能力を調査する。本ベンチマークでは URI のローカル名のみをリソース名として使用する。実世界知識データセットの例を表 2 に示す。

3.4.2 反実仮想知識データセット

反実仮想知識データセットは、実世界知識データセットを複数の観点から改変することで構築され、現実世界と矛盾する結論の導出を求めることで、語彙や表記の特徴への依存を調査する。LS は、RK の主語と目的語の反転、プロパティの定義域と値域の反転、クラスやプロパティの階層関係の並び替えを行ったデータセットである。RVA は、各リソースタイプに対応するランダムなリソースを割り当てたデータセットであり、リソースは DBpedia から取得する。GS は、RK の全リソースをランダムに再配置したデータセットである。GSC は、GS の各リソース名を、再配置前にその位置に配置されていたリソースタイプに応じ、DBpedia の命名規則に基づいて整形したデータセットである。

3.4.3 ランダム記号列データセット

ランダム記号列データセットは、リソース名にランダム記号列を割り当てることで構築され、非意味的な記号列を用いることで語彙による影響を排除し、より純粋な構造的推論能力を調査する。NS は、全リソースに完全にランダムな英数字記号列を割り当てたデータセットである。NSC は、リソースタイプごとに DBpedia の命名規則に従ったランダム英字記号列を生成し、各リソースに割り当てたデータセットである。

3.5 評価タスク設計

本ベンチマークでは、同一の推論タスクに対し、以下のような三段階のタスクレベルを設定する。

Lv1 系: 推論に必要な RDFS 推論規則または拡張 RDFS 推論規則を提示し、LLM は提示された規則を前提知識に適用して推論を実施する。

Lv2 系: 推論に必要な RDFS 推論規則集合を個別に提示し、LLM はそれらの規則を組み合わせで前提知識に適用して推論を実施する。

Lv3 系: 六つの RDFS 推論規則集合を提示し、LLM は必要な規則を選択および適用して推論結果と使用した規則名を出力する。

各レベルに対して、規則名と規則定義の両方を提示する条件（Lv1, Lv2, Lv3, 以下無印条件）、規則名のみを提示する条件（Lv1i, Lv2i, Lv3i, 以下 i 条件）、規則定義のみを提示する条件（Lv1a, Lv2a, Lv3a, 以下 a 条件）を設定する。

プロンプトの構成およびタスクレベルごとの指示の詳細は [細川 25] に示されている。

3.6 推論結果の評価

LLM の出力から正規表現を用いて推論結果を抽出し、データセットの期待出力（結論）と比較する。各トリプルについて、主語、述語、目的語の各要素が完全一致する場合にそのトリプルを正解と判定する。トリプル的一致数に基づいて適合率、再現率、F1 値を算出する。Lv3 系においては、LLM が選択した規則名の正確性についても同様に評価する。本ベンチマークでは、推論精度および規則選択精度の評価指標として F1 値を用いる。

3.7 統合指標

LLM 間の性能比較を容易にするため、以下の七つの統合指標を定義する。各指標は 0 から 1 の範囲を取り、高い値ほど優れた性能を示す。各指標の算出においては、規則数とタスクレベルの組み合わせ（Lv1:1-rule, Lv2:2-rule, Lv2:3-rule, Lv3:1-rule, Lv3:2-rule, Lv3:3-rule）ごとに対象データセットの F1 値平均を算出し、それらの平均を取る。

3.7.1 推論能力

RI (Real-world Inference) : 現実世界知識に基づく推論能力。Lv1~3 における RK の F1 値を対象として算出する。

SI (Structural Inference) : 純粋な構造的推論能力。Lv1~3 における NS の F1 値を対象として算出する。

3.7.2 規則選択能力

RRS (Real-world Rule Selection) : 現実世界知識における規則選択能力。Lv3 における RK の規則選択 F1 値を対象として算出する。

SRS (Structural Rule Selection) : 構造的推論における規則選択能力。Lv3 における NS の規則選択 F1 値を対象として算出する。

3.7.3 頑健性

VR (Vocabulary Robustness) : 語彙的混乱に対する頑健性。Lv1~3 の各推論タスクにおいて GSC の F1 値を NSC の F1 値で割った維持率を対象として算出する。維持率が 1 を超える場合は 1 とする。

NCR (Naming Convention Robustness) : リソースタイプの命名規則混乱に対する頑健性。Lv1~3 の各推論タスクにおいて GS の F1 値を GSC の F1 値で割った維持率を対象として算出する。維持率が 1 を超える場合は 1 とする。

3.7.4 規則知識

RDK (RDFS Entailment Rule Definition Knowledge) : RDFS 推論規則の定義知識活用能力。Lv1i:1-rule における NS の F1 値を対象として算出する。

4. 評価実験

4.1 実験設定

本ベンチマークの有効性を検証するため、GPT-4o mini (gpt-4o-mini-2024-07-18), GPT-4o (gpt-4o-2024-08-06), Llama 3.1 8B Instruct, Llama 3.1 70B Instruct, gpt-oss-20b, gpt-oss-120b を対象とした評価実験を実施した。サンプル数は、取得可能なデータ量に基づいて設定し、RK, LS, GS, GSC については各推論タスクあたり 400 サンプル、RVA, NS, NSC については各推論タスクあたり 100 サンプルを用いた。

4.2 実験結果

表 3 に各 LLM の統合指標、表 4 に主要な推論タスクにおけるデータセット別の推論精度、表 5 に主要な推論タスクにおける規則提示形式別の推論精度を示す。統合指標では、gpt-oss-20b が最も優れた精度を示し、次いで gpt-oss-120b が優

表 3: 統合指標による LLM 間の性能比較

LLM	RI	SI	RRS	SRS	VR	NCR	RDK
GPT-4o mini	0.74	0.71	0.85	0.89	0.80	0.82	0.59
GPT-4o	0.93	0.94	0.98	0.99	0.96	0.92	0.84
Llama 3.1 8B	0.49	0.51	0.57	0.60	0.45	0.71	0.32
Llama 3.1 70B	0.86	0.92	0.91	0.96	0.82	0.86	0.61
gpt-oss-20b	0.97	0.98	1.00	1.00	0.98	0.99	<u>0.91</u>
gpt-oss-120b	<u>0.94</u>	<u>0.95</u>	<u>0.99</u>	<u>0.99</u>	<u>0.98</u>	<u>0.99</u>	0.95

表 4: 主要な推論タスクにおけるデータセット別の推論精度

規則数	タスク レベル	LLM	データセット						
			RK	LS	RVA	GS	GSC	NS	NSC
1-rule	Lv1	GPT-4o mini	0.84	0.79	0.81	0.73	0.82	<u>0.88</u>	0.90
		GPT-4o	0.93	0.90	0.92	0.88	0.92	0.97	<u>0.93</u>
		Llama 3.1 8B	0.71	0.66	0.67	0.40	0.48	<u>0.69</u>	0.67
		Llama 3.1 70B	0.96	0.92	0.96	0.75	0.83	0.99	<u>0.98</u>
		gpt-oss-20b	0.97	0.97	0.98	0.98	0.98	<u>0.98</u>	0.98
		gpt-oss-120b	1.00	1.00	1.00	0.99	1.00	1.00	1.00
1-rule	Lv3	GPT-4o mini	0.65	0.60	0.59	0.49	0.56	0.73	<u>0.66</u>
		GPT-4o	0.91	0.89	0.88	0.83	<u>0.91</u>	0.87	0.83
		Llama 3.1 8B	0.35	0.35	0.32	0.16	0.20	<u>0.36</u>	0.40
		Llama 3.1 70B	0.84	0.77	<u>0.84</u>	0.58	0.69	0.93	0.84
		gpt-oss-20b	0.99	<u>0.99</u>	<u>0.98</u>	0.98	0.99	1.00	0.99
		gpt-oss-120b	0.99	0.99	1.00	0.98	0.99	1.00	<u>1.00</u>
3-rule	Lv2	GPT-4o mini	0.72	0.68	<u>0.68</u>	0.40	0.49	0.63	0.64
		GPT-4o	0.94	0.91	<u>0.94</u>	0.79	0.88	0.96	0.94
		Llama 3.1 8B	0.54	0.52	0.49	0.15	0.24	<u>0.55</u>	0.56
		Llama 3.1 70B	0.87	0.84	0.89	0.69	0.76	0.92	<u>0.92</u>
		gpt-oss-20b	<u>0.98</u>	0.98	0.97	0.98	0.98	0.99	0.98
		gpt-oss-120b	0.94	0.94	0.94	0.94	0.93	<u>0.95</u>	0.95
3-rule	Lv3	GPT-4o mini	0.64	0.60	0.58	0.30	0.38	0.56	0.53
		GPT-4o	0.89	0.86	<u>0.88</u>	0.71	0.82	0.88	0.86
		Llama 3.1 8B	0.41	0.36	0.34	0.10	0.17	<u>0.41</u>	0.44
		Llama 3.1 70B	0.84	0.77	0.84	0.59	0.69	0.88	0.87
		gpt-oss-20b	0.98	0.98	0.98	0.98	0.98	0.98	0.99
		gpt-oss-120b	0.95	0.96	0.96	0.95	0.94	<u>0.97</u>	0.98

注：データセット間の比較のため、1-rule では全データセットで評価可能な 4 種類の推論タスク (rdfs2, rdfs3, rdfs7, rdfs9) の平均を示す。

れた精度を示した一方、Llama 3.1 8B が最も低い精度を示した。データセット別では、NS で高い精度が得られる一方、GS では全 LLM で精度の低下が見られた。規則提示形式については、無印条件と a 条件で同等の精度が得られた一方、i 条件では精度が低下した。これらの結果についての詳細な分析は次節の考察で述べる。

4.3 考察

4.3.1 構造的推論能力と語彙および表記的特徴への依存

統合指標（表 3）において SI が RI と同等またはそれ以上の値を示す LLM が多く、語彙や表記的特徴を利用せずとも、LLM は RDFS 推論規則に基づく構造的推論能力を有していることが確認された。

しかし、リソース名に意味的な語彙が含まれる場合、LLM は構造的推論能力を有しているにもかかわらず、語彙や表記的特徴を利用した推論に依存する傾向がある。表 4 より、LS および RVA では、RK と比較して語彙の現実知識への不整合により多少の精度の低下は見られるものの、語彙の属するリソースタイプが正しく対応しているため、比較的高い精度を維持している。一方、語彙とリソースタイプの対応関係が混乱する GS では精度の低下が見られ、語彙が LLM の構造的推論を阻害することが示された。また、GSC が GS より改善する傾向は、LLM がリソースタイプの命名規則のパターンを推論時の手がかりとして活用していることを示している。

こうした語彙や表記的特徴への依存度は LLM によって異なる。同一モデルファミリー内ではパラメータ数が多いほど頑健性が高い傾向が確認された。一方、gpt-oss-20b は Llama

表 5: 主要な推論タスクにおける規則提示形式別の推論精度

規則数	タスク レベル	LLM	データセット						
			RK	LS	RVA	GS	GSC	NS	NSC
1-rule	Lv1	GPT-4o mini	0.84	0.79	0.81	0.73	0.82	<u>0.88</u>	0.90
		GPT-4o	0.93	0.90	0.92	0.88	0.92	0.97	<u>0.93</u>
	Lv1i	GPT-4o mini	0.53	<u>0.50</u>	0.45	0.18	0.21	0.45	0.45
		GPT-4o	0.88	<u>0.81</u>	0.80	0.48	0.68	0.80	0.73
3-rule	Lv1a	GPT-4o mini	0.84	0.79	0.83	0.66	0.77	0.82	0.87
		GPT-4o	0.94	0.91	0.92	0.88	0.91	0.96	<u>0.94</u>
	Lv3	GPT-4o mini	0.64	<u>0.60</u>	0.58	0.30	0.38	0.56	0.53
		GPT-4o	0.89	0.86	<u>0.88</u>	0.71	0.82	0.88	0.86
3-rule	Lv3i	GPT-4o mini	0.24	0.21	<u>0.23</u>	0.10	0.12	0.12	0.20
		GPT-4o	0.81	0.73	<u>0.79</u>	0.26	0.44	0.76	0.78
	Lv3a	GPT-4o mini	0.63	0.57	<u>0.59</u>	0.30	0.37	0.54	0.48
		GPT-4o	<u>0.90</u>	0.87	0.88	0.70	0.83	0.91	0.88

注：データセット間の比較のため、1-rule では全データセットで評価可能な 4 種類の推論タスク (rdfs2, rdfs3, rdfs7, rdfs9) の平均を示す。

3.1 70B よりパラメータ数が小さいにもかかわらず全指標で上回っており、例えば VR では gpt-oss-20b が 0.98 であるのに対し Llama 3.1 70B は 0.82, NCR では 0.99 に対し 0.86 であった (表 3)。これらの結果から、語彙や表記の特徴への依存度にはパラメータ数だけでなく学習方法やアーキテクチャの違いも寄与することが示唆される。

4.3.2 事前知識の役割と限界

表 5 より、規則名と規則定義の両方を提示する無印条件と規則定義のみを提示する a 条件では概ね同等の精度が得られており、規則名の有無による推論精度の差は見られない。一方、規則名のみを提示する i 条件では精度の低下が見られ、規則定義を提示することで推論精度が向上することが示された。

i 条件における低下の程度は LLM によって異なる。GPT-4o mini は全データセットで低下を示した一方、GPT-4o は GS および GSC を除けば低下の程度が GPT-4o mini と比較して小さかった。これは、パラメータ数や学習データ量の違いにより、GPT-4o が RDFS 推論規則の定義知識をより豊富に保持していることを示唆している。他のモデルファミリーにおいても、RDK は Llama 3.1 70B が 0.61 であるのに対し 8B は 0.32 と同様の傾向が見られ、この解釈と整合する。しかし、GPT-4o であっても GS および GSC では GPT-4o mini と同様に低下が生じており、語彙とリソースタイプの対応関係が混乱するデータセットに対して事前知識のみで推論を行うことの限界が示された。

これらの結果から、LLM が RDFS 推論規則の定義知識を事前に獲得している場合でも、プロンプトにおいて規則定義を明示的に提示することが推論の安定化に有効であることが示唆される。

4.3.3 推論失敗パターンの分析

GPT-4o mini および Llama 3.1 8B では、事前学習知識に基づく情報補完による推論失敗が確認された。例えば、rdfs2 (定義域による型推論) のみが必要なタスクにおいて、GPT-4o mini が明示的に提示されていない値域情報を補完し、不要な rdfs3 (値域による型推論) 規則を適用するケースが観察された。このような事前学習知識による情報補完は、これらの LLM が明示的に提示された前提知識および規則のみに基づく推論というタスク制約を遵守することの困難さを示している。

また、RDFS 語彙の誤用による推論失敗も確認された。Llama 3.1 70B および gpt-oss-120b では、Lv1:rdfs11 条件において、`rdfs:subClassOf` とすべき箇所を `rdf:subClassOf` と出力するケースが発生し、推論精度が低下した。推論の構造自体は正

しく実行されているものの、RDFS 語彙の使用に誤りが生じている。この現象の原因は明確ではないが、学習データにおける特定のパターンが Lv1:rdfs11 条件で顕在化した可能性が考えられる。

5. おわりに

本研究では、RDFS 推論規則に基づく LLM の論理推論能力を評価するベンチマークを提案し、商用およびオープンウェイト LLM を用いて評価実験を行った。実験の結果、LLM は構造的推論能力を有する一方で、語彙や表記の特徴に依存する傾向が確認された。また、一定規模以上の LLM においては、パラメータ数よりも学習方法やアーキテクチャが推論精度に大きく寄与する可能性が示唆された。さらに、高難度条件ではタスク制約の遵守が困難な LLM もあり、事前学習知識による情報補完が生じることが示されたが、この挙動は知識の不完全性が避けられないセマンティック Web 環境において有用に機能する可能性がある。これらの知見は、セマンティック Web における LLM 活用の可能性と限界を示している。今後の課題として、失敗パターンのより詳細な分析、および Web Ontology Language (OWL) への拡張が挙げられる。

謝辞

本研究成果の一部は、国立研究開発法人新エネルギー・産業 技術総合開発機構 (NEDO) の委託業務 (JPNP20006, JPNP25006) の結果得られたものです。本研究は JSPS 科研費 23K11221, 25K03232 の助成を受けたものです。

参考文献

- [Huang 23] Huang, J. and Chang, K.: Towards reasoning in large language models: A survey, in *Findings of the Association for Computational Linguistics: ACL 2023*, pp. 1049–1065 (2023)
- [Morishita 24] Morishita, T., Yamaguchi, A., Morio, G., and Sogawa, Y.: JFLD: A Japanese benchmark for deductive reasoning based on formal logic, in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 3034–3049 (2024)
- [Ozeki 24] Ozeki, H., Oba, S., Mita, M., Hisamoto, S., and Yoshinaga, N.: NeuBAROCO: A Japanese dataset for evaluation of syllogistic reasoning ability of language models, in *Proceedings of the 30th Annual Meeting of the Association for Natural Language Processing*, pp. 1776–1781 (2024)
- [Wu 23] Wu, W., Jiang, C., Jiang, Y., Xie, P., and Tu, K.: Do PLMs Know and Understand Ontological Knowledge?, in *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 3080–3101, Association for Computational Linguistics (2023)
- [細川 25] 細川 泰智, シュデシナ チャクラボルティ, 森田 武史: RDF スキーマ推論規則を対象とした大規模言語モデルの推論能力の段階的評価, 人工知能学会第二種研究会資料, Vol. 2025, No. SWO-066, p. 07 (2025)