

RDFS-LLM-Bench

細川泰智¹、チャクラボルティ シュデシナ¹、森田武史^{1 2}

1. 青山学院大学

2. 産業技術総合研究所

背景：大規模言語モデル（LLM）と形式推論

LLMの様々な能力を対象とした評価ベンチマークの提案

言語理解・文章生成・対話・推論・コーディングなど幅広い能力を評価

▶ 人工知能の汎用性の向上を追求

LLMの論理推論能力に関する課題

明示的推論ではなく、**事前学習知識に依存**して問題を解決する傾向

▶ 「推論したのか、記憶から答えたのか」の切り分けが重要

オントロジー推論を対象とした評価の不足

Semantic Webにおける知識統合の基盤としてRDFスキーマ（RDFS）は重要

▶ LLMのRDFS推論能力の体系的評価は未開拓

Semantic WebとRDFSの重要性

- RDFSはSemantic Webにおけるオントロジー言語の基礎層
- 推論規則に基づき、前提トリプルから新たなトリプルを導出

RDFS推論規則

W3Cによって標準化された、RDFSを用いて推論を行うための13種類の規則

規則	前提	結論
rdfs2	$\langle i, \text{rdfs:domain}, X \rangle, \langle a, i, b \rangle$	$\langle a, \text{rdf:type}, X \rangle$
rdfs3	$\langle i, \text{rdfs:range}, X \rangle, \langle a, i, b \rangle$	$\langle b, \text{rdf:type}, X \rangle$
rdfs5	$\langle i, \text{rdfs:subPropertyOf}, j \rangle, \langle j, \text{rdfs:subPropertyOf}, k \rangle$	$\langle i, \text{rdfs:subPropertyOf}, k \rangle$
rdfs7	$\langle i, \text{rdfs:subPropertyOf}, j \rangle, \langle a, i, b \rangle$	$\langle a, j, b \rangle$
rdfs9	$\langle X, \text{rdfs:subClassOf}, Y \rangle, \langle a, \text{rdf:type}, X \rangle$	$\langle a, \text{rdf:type}, Y \rangle$
rdfs11	$\langle X, \text{rdfs:subClassOf}, Y \rangle, \langle Y, \text{rdfs:subClassOf}, Z \rangle$	$\langle X, \text{rdfs:subClassOf}, Z \rangle$

▶ LLMがRDFS推論をどの程度実行できるかを体系的に評価したい

関連研究 1 : オントロジー推論評価

Wu et al. [ACL 2023] — 最も直接的な先行研究

- PLM (BERT/RoBERTa) が6つのRDFSルールを保持・理解・適用できるかを評価
- DBpedia・Wikidataから実世界データセットを構築
- 評価形式: マスク付き言語モデリング (穴埋め)

▶ PLMはオントロジー知識を一部保持するが、domain/range制約に弱いと報告

Zhang et al. OntoURL [2025]

- OWLオントロジー用大規模ベンチマーク (40オントロジー × 8ドメイン × 57k問題)
- 理解・推論・学習の3軸で20のオープンソースLLMを評価

▶ 理解は良好だが、推論・学習能力には大きな改善余地があることを示唆

関連研究 2 : 「推論能力」と「記憶した知識」をどう切り分けるか？

Morishita et al. JFLD [LREC-COLING 2024]

- ・ 日本語の演繹推論ベンチマーク
- ・ Multilingual WordNetからランダムに語彙を選び、反実仮想設定を構築

Ozeki et al. NeuBAROCO [ACL 2024]

- ・ 三段論法の信念バイアス (belief bias) を研究
 - ・ 常識に反する論理的に正しい結論をバイアス誘発条件で提示 → 精度低下
- ▶ LLMは信念と論理が衝突すると誤る

Mai et al. [ISWC 2024]

- ・ ドメイン用語を発音可能なでたらめ語 (gibberish) に置換
- ▶ LLMは語彙的特徴に依存し、概念間の関係を一貫して推論できない

[3] Morishita et al., "JFLD: A Japanese Benchmark for Deductive Reasoning Based on Formal Logic", Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING), pp. 9526–9535, 2024.

[4] Ozeki et al., "Exploring Reasoning Biases in Large Language Models Through Syllogism: Insights from the NeuBAROCO Dataset", Findings of the Association for Computational Linguistics (ACL), pp. 16063–16077, 2024.

[5] Mai et al., "Do LLMs Really Adapt to Domains? An Ontology Learning Perspective", The Semantic Web – ISWC 2024, Lecture Notes in Computer Science, pp. 126–143, Springer, 2025.

先行研究の課題と本研究の位置づけ

先行研究の3つの課題

- ・ 実世界知識データへの偏り ▶ 構造的推論と事前学習知識の利用を切り分けられない
- ・ 単一ルールのみ評価 ▶ 実運用に必要な複数規則の適用が未評価
- ・ 評価形式の乖離 ▶ 穴埋め形式 ≠ Semantic Webの実運用（RDFトリプル直接出力が必要）

RDFS-LLM-Bench の設計方針

- ・ 3種のデータセット：実世界知識 / 反実仮想 / ランダム記号
 - ▶ 語彙依存と構造推論能力を分離計量
- ・ 19の推論パターン：1～3規則の適用をカバー
- ・ RDFトリプル直接出力で評価
 - ▶ 言語的曖昧性を排除
- ・ 7つの統合指標で多面的評価

RDFS-LLM-Bench 概要

ベンチマークの全体構造

- ・ 評価対象：6つのRDFS推論規則（rdfs2, rdfs3, rdfs5, rdfs7, rdfs9, rdfs11）
- ・ 推論パターン：1～3規則の組み合わせによる19種
- ・ データセット：実世界知識 1種 / 反実仮想知識 4種 / ランダム記号 2種
- ・ プロンプト条件：提示規則タイプ 2種 × 規則フォーマット 3種
- ・ 評価指標：7つの統合指標（推論能力・規則選択能力・頑健性）

タスク設計



推論パターンの構築

19種類の推論パターン

- ・ 1-rule : 6パターン、2-rule : 7パターン、3-rule : 6パターン → 計19パターン
- ・ 2/3-rule は複数規則の前提トリプルを組み合わせで構築
 - ・ 結論トリプルをRDFS推論器（Apache Jena Inference API）を用いて導出
 - ・ Jena GenericRuleReasoner を用いて、当該規則から導出可能な結論のみを生成

推論規則	前提	結論
rdfs3	<i, rdfs:range, X>, <a, i, b>	<b, rdf:type, X>
rdfs5	<i, rdfs:subPropertyOf, j>, <j, rdfs:subPropertyOf, k>	<i, rdfs:subPropertyOf, k>
rdfs7	<i, rdfs:subPropertyOf, j>, <a, i, b>	<a, j, b>



推論パターン	前提	結論
rdfs3_5_7	<k, rdfs:range, X> <i, rdfs:subPropertyOf, j> <j, rdfs:subPropertyOf, k> <a, i, b>	<b, rdf:type, X> <i, rdfs:subPropertyOf, k> <a, j, b> <a, k, b>

実世界知識データセット (RK)

- DBpedia・Wikidata・schema.org の SPARQL エンドポイントから収集
- Wikidata のIDは英語ラベルをDBpedia風 camelCase に変換して使用
- 各推論パターンにつき400サンプルを使用

※ 95%信頼区間・誤差5%の有限母集団修正式の上限（約385）を超えるよう設定

規則	前提	結論
rdfs3	<i, rdfs:range, X>, <a, i, b>	<b, rdf:type, X>



SPARQLクエリで検索



a	Kachidoki_Bridge
b	Sumida_River
i	crosses
X	River

Linked Open Dataから対応するトリプルを取得



前提	<crosses, rdfs:range, River>, <Kachidoki_Bridge, crosses, Sumida_River>
結論	<Sumida_River, rdf:type, River>

反実仮想知識データセット (LS・RVA・GS・GSC)

- ・ 実世界のオントロジー（主に実世界知識データセット）を改変
- ・ 語彙的手がかり（語彙共起・意味）と命名規則を独立に操作した4種のデータセットを構築

LS

主語/述語、定義域/値域の入れ替え、階層関係のシャッフル

RVA

DBpediaからリソースタイプ別にランダム割当

GS

全リソースをシャッフル

GSC

GSの各リソース名をDBpediaの命名慣習に従い、配置先のタイプ本来の命名規則に変換

※ クラスはPascalCase、インスタンスはUpper_Snake_Case、プロパティはcamelCase

ランダム記号データセット (NS・NSC)

すべてのリソースを意味を持たない文字列で構築

NS

8文字英数ランダム文字列

NSC

DBpedia形式の命名規則付きランダム文字列

※ クラスはPascalCase、インスタンスはUpper_Snake_Case、プロパティはcamelCase

プロンプト条件

提示規則タイプ（2種） × 規則フォーマット（3種） の組み合わせでプロンプト条件を定義

提示規則タイプ

NRP：対象の推論パターンに必要な規則のみ提示

ARP：6つの規則すべてを提示し、使用した規則も出力させる

規則フォーマット

full：規則名 + 規則定義

name：規則名のみ

def：規則定義のみ

スコアリング

LLMの出力を正解トリプルと比較しF1スコアで評価

※ 出力から前提トリプルを除去して正解トリプルと比較（推論エンジンの挙動を許容）

Strict モード

許容する形式：<s, p, o>（プロンプト内の規則・前提トリプルと同じ形式）

目的：推論と書式遵守を統合した厳格な評価

Flex モード

許容する形式：<s, p, o>、<s,p,o>、<s , p , o>、<s p o>

目的：書式の揺れを吸収し、推論能力そのものに焦点

統合指標

7つの指標を 推論能力・規則選択能力・頑健性 の3軸で定義

※ 各指標は提示規則タイプ（NRP/ARP）× 規則数（1/2/3-rule）の6セルで平均

推論能力

RI（実世界知識下での推論能力）：RK上の推論F1

SI（構造的推論能力）：NS上の推論F1

規則選択能力

RRS（実世界知識推論下での規則選択能力）：RK上の規則選択F1

SRS（構造的推論下での規則選択能力）：NS上の規則選択F1

頑健性

VR（語彙意味の混乱への頑健性）：F1_GSC / F1_NSC

TR（命名規則への依存度）：F1_GS / F1_GSC

RDI（規則定義への依存度）：F1_name / F1_full

実験結果① 統合指標による評価結果

6つのLLMを統合指標で比較（Flex評価モード）

LLM	RI	SI	RRS	SRS	VR	TR	RDI
gpt-oss-120b	0.996	0.998	1.000	1.000	0.987	0.994	0.935
gpt-oss-20b	0.986	0.990	0.999	0.999	0.985	0.994	0.884
GPT-4o	0.932	0.935	0.980	0.990	0.958	0.918	0.852
GPT-4o mini	0.740	0.711	0.846	0.889	0.797	0.817	0.392
Llama 3.1 70B	0.907	0.940	0.902	0.961	0.814	0.856	0.565
Llama 3.1 8B	0.510	0.522	0.587	0.611	0.490	0.701	0.278

※ RI：実世界推論、SI：構造的推論、RRS：実世界推論規則選択、SRS：構造的推論規則選択、VR：語彙意味の混乱への頑健性、TR：命名規則への依存度、RDI：規則定義への依存度（1に近いほど性能・頑健性が高く、依存度が低い）

主要知見

- ・ SI $\approx$ RI または SI > RI（多数モデル） ▶ LLMは語彙手がかりなしでもRDFS推論を実行できる
- ・ 推論モデル（gpt-oss）はすべての指標で高性能、小規模（20B）でも強い
- ・ RDIの差が大きい ▶ 規則定義の提示が非推論モデルの安定性に重要

実験結果② データセット別の評価結果

データセット別 推論F1 (full設定)

LLM	RK	LS	RVA	GS	GSC	NS	NSC
gpt-oss-120b	0.996	0.997	0.995	0.980	0.985	0.998	0.996
gpt-oss-20b	0.986	0.987	0.986	0.975	0.977	0.990	0.988
GPT-4o	0.932	0.907	0.921	0.807	0.877	0.935	0.911
GPT-4o mini	0.740	0.708	0.705	0.466	0.549	0.711	0.689
Llama 3.1 70B	0.907	0.855	0.906	0.650	0.751	0.940	0.926
Llama 3.1 8B	0.510	0.481	0.459	0.210	0.277	0.522	0.532

※ RK：実世界知識、LS：主語/述語・定義域/値域・階層の入れ替え、RVA：リソースタイプ別ランダム割当、GS：全リソースシャッフル、GSC：GSに命名規則を付与、NS：意味を持たない文字列、NSC：NSに命名規則を付与

主要知見

- ・ 推論モデル: 全データセットでF1 > 0.97 を維持 → 語彙・命名規則に依存しない構造推論
- ・ 非推論モデル: GS で大幅劣化 ▶ 例: GPT-4o mini は RK 0.740 → GS 0.466 (▲37%)
- ・ GSC > GS が一貫 (命名規則が手がかりとして利用されている証拠)
- ・ LS/RVA は 劣化が小 (型対応・命名規則の保持が効いている)

考察① 推論モデルの推論挙動（定性分析）

gpt-oss モデルの推論トレース分析から得られた知見

GS下での頑健性の説明

- ・ 明示的な変数置換と規則適用可能性の系統的チェックを実施
- ・ 意味的に異常なトリプル（例：地名を述語に使用）でも形式的な規則適用を選好
- ・ 非推論モデルはこれを1ステップで暗黙的に処理する必要がある

multi-rule 推論での安定性

- ・ 候補規則を反復適用し、導出トリプルを蓄積するため、規則数の増加に対して頑健
- ・ 非推論モデルは規則数増加で性能劣化（規則ごとの個別チェックの欠如）

規則選択能力の高さ

- ・ 系統的な規則ごとのチェック挙動が ARP 条件下の規則選択能力にも寄与
- ・ gpt-oss-120b は RRS / SRS とともに 1.000 を達成

考察② パラメータスケールと規則フォーマットの影響

パラメータスケールの効果

- ・ 非推論モデル：スケール拡大で頑健性が大幅向上（Llama・GPT-4oファミリー）
- ・ 推論モデル：20B でも既に頑健、120B との差は他ファミリーより小さい
- ▶ 明示的な推論手続きは小規模でも頑健性を実現可能

規則フォーマットの影響

- ・ def 設定は full 設定と同等、name 設定は性能低下
- ▶ 規則定義の明示的提示が推論を安定化
- ・ gpt-oss は name 設定下で規則定義を再構成・整理してから回答
- ▶ full 設定の挙動を部分的に回復（高い RDI スコア：0.935 / 0.884）
- ・ 120B は 20B より正確に規則定義を再構成
- ▶ スケール拡大により規則知識の保持と忠実な再構成が改善

まとめ

RDFS-LLM-Bench

- ・ 19推論パターン × 3データセット種別 × 7統合指標
- ・ RDFトリプル直接出力で評価、全コンポーネント公開

主要な知見

- ・ LLMは語彙手がかりなしでも非自明なRDFS推論を一定程度実行できる
- ・ 推論モデルは反実仮想知識データでも高い頑健性を維持
- ・ 非推論モデルは語彙・表記的特徴への依存が顕著
- ・ 規則定義の明示的提示が推論の安定化に寄与

今後の研究方向

- ・ Chain-of-Thought等のプロンプト手法で非推論モデルのギャップは縮まるか？
- ・ OWL等より表現力の高いオントロジー言語への拡張

FIN

ご清聴ありがとうございました