

RDFスキーマ推論規則を対象とした 大規模言語モデルの推論能力の段階的評価

細川泰智¹、チャクラボルティ シュデシナ¹、森田武史^{1 2}

1. 青山学院大学

2. 産業技術総合研究所

SIG-SWO-065-07



研究背景

大規模言語モデル（LLM）の様々な能力の評価手法が提案

言語理解能力、文章生成能力、対話能力、推論能力、コーディング能力など
＞人工知能の汎用性の向上を追求

LLMの論理推論能力に関する課題

LLMは明示的推論ではなく、**事前学習知識に依存**して問題を解決する傾向がある

オントロジー推論の重要性

質問応答などの自然言語処理タスクにおいて重要
＞LLMのオントロジーを対象とした能力の評価は不十分

関連研究

オントロジー推論評価

[Wu-2023]

- ・ 手法 6つのRDFS推論規則で評価
- ・ 評価 自然言語ベース、オントロジーの記憶と推論

反実仮想条件における推論評価

現実と異なる前提に基づき推論を行う

[Ozeki-2024]

- ・ 手法 信念相反条件での推論
- ・ 評価 三段論法での推論

[Morishita-2024]


- ・ 手法 定数・述語のランダム化
- ・ 評価 多段演繹規則での推論

本研究の位置付け

従来研究との差異

- ・ 評価の厳密性 RDFSトリプル形式
- ・ 複雑な推論 複数規則の組み合わせ
- ・ 体系的評価 3段階のタスクレベル
- ・ 反実仮想条件の構築 8種類の変換手法

反実仮想条件における推論の例



オントロジーを対象とした能力の検証について

オントロジー推論評価

[Wu-2023]

- ・手法 6つのRDFS推論規則で評価
- ・評価 自然言語ベース、オントロジーの記憶と推論

1. 理解・処理能力

現状 自然言語ベースの評価

厳密なオントロジーの概念の理解や処理能力の検証としては不十分

＞Webオントロジー言語を用いた**定量的評価**が必要

2. 論理推論能力

現状 基本的な推論タスク（単一のRDFS推論規則での推論）のみの評価

＞**複雑な推論タスク**での評価の必要あり

反実仮想条件の作成方法について

反実仮想条件での推論評価

[Ozeki-2024]

- ・手法 信念相反条件での推論
- ・評価 三段論法での推論

[Morishita-2024]

- ・手法 定数・述語のランダム化
- ・評価 多段演繹規則での推論

1. 従来手法の限界

表面的な語彙変更のみ or 現実から大きく乖離した条件

- ・ある動物は人間である & すべての動物はトマトである
→ ある人間はトマトである [Ozeki-2024]
- ・定数・述語のランダム化による語彙置換 [Morishita-2024]

2. 予備実験結果

RDFS推論規則を対象とした予備実験をGPT-4o miniで実施

- 現実知識 vs ランダム語彙 vs 記号列推論で有意差なし
- ランダム語彙は、記号操作の推論と同様に処理できる可能性

反実仮想条件の作成方法の見直し

現実知識の構造を改変した前提をもとに推論

➢ LLMの知識基盤と矛盾する推論を要求

➢ パターンマッチングや事前学習知識での推論を防止

研究目的と主要貢献

RDFスキーマ推論規則を用いた
LLMの論理推論能力の包括的評価手法の確立

主要貢献

包括的・体系的評価

- ・ **RDFS推論規則**に基づく評価
- ・ LLMの論理推論能力を体系的に測定

厳密で定量的な評価手法の確立

- ・ **RDFSトリプル形式**での評価（自然言語は不使用）
- ・ 言語的曖昧性を排除した定量的な評価

多様なデータセットと段階的タスク設計

- ・ **10種類のデータセット**を構築
- ・ **6段階のタスクレベル**で規則適用・選択能力を検証

提案手法の概要

1. 使用する推論規則と組み合わせの設定

- ・ 6種類のRDFS推論規則の選定
- ・ 複数の規則を用いる推論タスクを設定

2. 評価用データセットの作成

- ・ 意味的データセット（実世界知識・反実仮想知識）
- ・ 非意味的データセット（ランダム記号列）

3. 出力結果の評価

- ・ 6段階のタスクレベルの設定
- ・ 推論結果と選択した規則をもとに定量評価

6種類のRDFS推論規則の選定

RDFS推論規則

W3Cによって標準化された、RDFSを用いて推論を行うための13種類の規則

- 本研究では、推論で使う最も重要な6種類の規則を使用

規則	前提	結論
rdfs2	$\langle i, \text{rdfs:domain}, X \rangle, \langle a, i, b \rangle$	$\langle a, \text{rdf:type}, X \rangle$
rdfs3	$\langle i, \text{rdfs:range}, X \rangle, \langle a, i, b \rangle$	$\langle b, \text{rdf:type}, X \rangle$
rdfs5	$\langle i, \text{rdfs:subPropertyOf}, j \rangle, \langle j, \text{rdfs:subPropertyOf}, k \rangle$	$\langle i, \text{rdfs:subPropertyOf}, k \rangle$
rdfs7	$\langle i, \text{rdfs:subPropertyOf}, j \rangle, \langle a, i, b \rangle$	$\langle a, j, b \rangle$
rdfs9	$\langle X, \text{rdfs:subClassOf}, Y \rangle, \langle a, \text{rdf:type}, X \rangle$	$\langle a, \text{rdf:type}, Y \rangle$
rdfs11	$\langle X, \text{rdfs:subClassOf}, Y \rangle, \langle Y, \text{rdfs:subClassOf}, Z \rangle$	$\langle X, \text{rdfs:subClassOf}, Z \rangle$

複数の規則を用いる推論タスクを設定

- 複数のRDFS推論規則を組み合わせた推論タスクを作成
- 前提を結合し、結論をRDFS推論器（Apache Jena Inference API）を用いて導出
 - 選定したRDFS推論規則のみをカスタムルールとして定義
 - Jena GenericRuleReasoner を用いて、当該規則から導出可能な結論のみを生成
- 拡張RDFS推論規則として定義（例：rdfs3_5_7）

規則	前提	結論
rdfs3	<i, rdfs:range, X>, <a, i, b>	<b, rdf:type, X>
rdfs5	<i, rdfs:subPropertyOf, j>, <j, rdfs:subPropertyOf, k>	<i, rdfs:subPropertyOf, k>
rdfs7	<i, rdfs:subPropertyOf, j>, <a, i, b>	<a, j, b>



規則	前提	結論
rdfs3_5_7	<k, rdfs:range, X> <i, rdfs:subPropertyOf, j> <j, rdfs:subPropertyOf, k> <a, i, b>	<b, rdf:type, X> <i, rdfs:subPropertyOf, k> <a, j, b> <a, k, b>

評価用データセットの作成の概要

意味的データセット

実世界知識データセット

Linked Open Dataから取得したデータで構成される

前提	<crosses, rdfs:range, River>, <Kachidoki_Bridge, crosses, Sumida_River>
結論	<Sumida_River, rdf:type, River>

反実仮想知識データセット

現実と異なる知識を基に構成される

非意味的データセット

ランダム記号列データセット

英数字のランダムな記号列で構成される

前提	<E1GXDFhK, rdfs:range, WBP63Px4>, <WxtQpDiD, E1GXDFhK, jjTJX0BE>
結論	<jjTJX0BE, rdf:type, WBP63Px4>

実世界知識データセットの作成方法

規則	前提	結論
rdfs3	<i, rdfs:range, X>, <a, i, b>	<b, rdf:type, X>

↓ 合致するデータ構造をSPARQLクエリを用いて検索



DBpedia, Wikidata, Linked Open Vocabularies



a	Kachidoki_Bridge
b	Sumida_River
i	crosses
X	River

Linked Open Dataから対応するリソースを取得

データセットを作成



規則	if <i, rdfs:range, X> and <a, i, b> then <b, rdf:type, X>
前提	<crosses, rdfs:range, River>, <Kachidoki_Bridge, crosses, Sumida_River>
結論	<Sumida_River, rdf:type, River>

反実仮想知識データセットの作成方法


以下の8種類の手順で、主に実世界知識データセットを改変して作成

データセット名	作成方法
S	リソースの反転、階層関係の並び替え
NA	“not”をすべてのクラス・プロパティ名の先頭に付与
NR	“not”をランダムなクラス・プロパティ名の先頭に付与
SNA	Sを適用後、NAを適用
SNR	Sを適用後、NRを適用
GS	全リソースの一括シャッフル
GSC	GSを適用後、リソースのタイプに応じてリソース名を整形（DBpediaの形式）
RND	リソースの種類ごとに、ランダム語彙を割り当て（参考： [Morishita-2024] ）


反実仮想知識データセットSの作成例

Sの作成手順：リソースの反転、階層関係の並び替え

実世界知識データ (RK)




反実仮想知識データ (S)




反実仮想知識データセットNRの作成例

NAの作成手順：“not”をランダムなクラス・プロパティ名の先頭に付与

実世界知識データ (RK)




反実仮想知識データ (S)




反実仮想知識データセットGSの作成例

GSの作成手順：全リソースの一括シャッフル

実世界知識データ (RK)



反実仮想知識データ (GS)




反実仮想知識データセットGSCの作成例

GSCの作成手順：GSの適用後、リソースのタイプに応じてリソース名を整形（DBpediaの形式）

反実仮想知識データ（GS）

反実仮想知識データ（GSC）



タイプ	命名慣習
クラス	PascalCase
インスタンス	Upper_Snake_Case
プロパティ	camelCase

ランダム記号列データセットの作成方法

英数字（大文字・小文字）を組み合わせた8文字の記号列から語彙を作成

規則	if $\langle i, \text{rdfs:range}, X \rangle$ and $\langle a, i, b \rangle$ then $\langle b, \text{rdf:type}, X \rangle$
前提	$\langle E1GXDFhK, \text{rdfs:range}, WBP63Px4 \rangle, \langle WxtQpDiD, E1GXDFhK, jjTJX0BE \rangle$
結論	$\langle jjTJX0BE, \text{rdf:type}, WBP63Px4 \rangle$

データセットごとのサンプル数

実世界知識データセット (RK)

取得可能なデータ数から評価に利用するサンプルサイズを計算 (各規則400個)

反実仮想知識データセット (S・NA・NR・SNA・SNR・GS・GSC)

実世界知識データセットのサンプル数と同じ (各規則400個)

反実仮想知識データセット (RND)

各規則100個

ランダム記号列データセット (NS)

各規則100個

評価手法の設計

評価の手順

1. 規則・前提知識をLLMに提示し、推論を実行
2. 出力結果の定量評価

評価手法の設計

6段階のタスクレベル

同一の推論タスクに対し、推論規則の提示方法を変更した三つのタスクレベルを設定（Lv1 - Lv3）

レベル	タスク
1	・ 推論に必要なRDFS推論規則または拡張RDFS推論規則と前提知識を提示 ・ 前提知識に適用し、推論結果を出力
2	・ 推論に必要なRDFS推論規則集合と前提知識を提示 ・ 前提知識に適用し、推論結果を出力
3	・ 六つのRDFS 推論規則集合（rdfs2,3,5,7,9,11）と前提知識を提示 ・ 適切な規則を選択して前提知識に適用し、推論結果と選択した規則を出力

各レベルに対し、推論規則の定義を提示せず、規則名のみを与える条件を設定（Lv1i - Lv3i）

タスクLv1のプロンプト例（rdfs2とrdfs3を用いた推論）

Given the following rule and premise knowledge:

Rule:

if <i, rdfs:domain, X> and <i, rdfs:range, Y> and <a, i, b> then <a, rdf:type, X> and <b, rdf:type, Y>

Premise Knowledge:

<nearestCity, rdfs:domain, Place>, <nearestCity, rdfs:range, PopulatedPlace>, <Calamus_Swamp, nearestCity, Ohio>

Note: The variable names used in the rule (e.g., a, b, i, j, k, X, Y, Z, W) are placeholders and do not represent actual classes, properties, or instances.

They are used solely for describing the rule structure.

Solely based on this rule and the premise knowledge, output the inferred RDFS triples.

Enclose each triple in "<" and ">".

Never use the "http://" format in the triple.

Output all triples that can be derived from this rule and do not include any additional text or descriptions.

- ・ 推論に必要な**RDFS推論規則または拡張RDFS推論規則**と**前提知識**を提示
- ・ **前提知識に適用し、推論結果をRDFSトリプルとして出力するよう指示**

タスクLv2のプロンプト例（rdfs2とrdfs3を用いた推論）

Given the following rules and premise knowledge:

Rules:

rdfs2: if <i, rdfs:domain, X> and <a, i, b> then <a, rdf:type, X>

rdfs3: if <i, rdfs:range, X> and <a, i, b> then <b, rdf:type, X>

Premise Knowledge:

<nearestCity, rdfs:domain, Place>, <nearestCity, rdfs:range, PopulatedPlace>, <Calamus_Swamp, nearestCity, Ohio>

Note: The variable names used in these rules (e.g., a, b, i, j, k, X, Y, Z, W) are placeholders and do not represent actual classes, properties, or instances.

They are used solely for describing the rule structure.

Solely based on these rules and the premise knowledge, output the inferred RDFS triples by combining these rules.

Enclose each triple in "<" and ">".

Never use the "http://" format in the triple.

Output all triples that can be derived from these rules and do not include any additional text or descriptions.

- ・ 推論に必要なRDFS推論規則集合と前提知識を提示
- ・ 前提知識に適用し、推論結果をRDFSトリプルとして出力するよう指示

タスクLv3のプロンプト例（rdfs2とrdfs3を用いた推論）

Given the following rules and premise knowledge:

Rules:

rdfs2: if <i, rdfs:domain, X> and <a, i, b> then <a, rdf:type, X>

rdfs3: if <i, rdfs:range, X> and <a, i, b> then <b, rdf:type, X>

rdfs5: if <i, rdfs:subPropertyOf, j> and <j, rdfs:subPropertyOf, k> then <i, rdfs:subPropertyOf, k>

rdfs7: if <i, rdfs:subPropertyOf, j> and <a, i, b> then <a, j, b>

rdfs9: if <X, rdfs:subClassOf, Y> and <a, rdf:type, X> then <a, rdf:type, Y>

rdfs11: if <X, rdfs:subClassOf, Y> and <Y, rdfs:subClassOf, Z> then <X, rdfs:subClassOf, Z>

Premise Knowledge:

<nearestCity, rdfs:domain, Place>, <nearestCity, rdfs:range, PopulatedPlace>, <Calamus_Swamp, nearestCity, Ohio>

---省略---

Solely based on these rules and the premise knowledge, output the inferred RDFS triples by selecting and combining these rules as necessary.

---省略---

At the end of your response, list all rule names you used in the format: [used_rules: rdfsN, ...].

Replace N with the actual rule numbers you applied.

Enclose the list in "[" and "]", use the exact key name "used_rules:", and separate each rule name with a comma.

Use only rule names from the following list: rdfs2, rdfs3, rdfs5, rdfs7, rdfs9, rdfs11.

Output all triples that can be derived from these rules and do not include any additional text or descriptions.

The only exception is the [used_rules: ...] line at the end of your response.

- **RDFS推論規則集合（rdfs2,3,5,7,9,11）と前提知識を提示**
- 適切な規則を選択して前提知識に適用し、推論結果をRDFSトリプルとして出力するよう指示
- 選択した規則をリストとして出力するよう指示

出力結果の定量評価

1. 出力から推論結果を抽出（Lv3、Lv3i の場合は、選択した規則の抽出も行う）
2. RDFS推論器による結論と比較（Lv3、Lv3i の場合は、設定した規則との比較も行う）
3. 適合率、再現率、F1値を用いてスコア化

指標	推論結果の評価	選択した規則の評価
適合率	$\frac{\text{LLM出力内の正解トリプル数}}{\text{LLMの出力したトリプル数}}$	$\frac{\text{LLM出力内の正解規則数}}{\text{LLMの出力した規則数}}$
再現率	$\frac{\text{LLM出力内の正解トリプル数}}{\text{正解トリプルの総数}}$	$\frac{\text{LLM出力内の正解規則数}}{\text{正解規則の総数}}$
F1値	$2 \cdot \frac{\text{適合率} \cdot \text{再現率}}{\text{適合率} + \text{再現率}}$	

評価実験の概要

- GPT-4o miniおよびGPT-4oを対象
- 19種類の推論タスクを実施
 - 1-rule : rdfs2, rdfs3, rdfs5, rdfs7, rdfs9, rdfs11
 - 2-rule : rdfs2_3, rdfs2_7, rdfs2_9, rdfs3_7, rdfs3_9, rdfs5_7, rdfs9_11
 - 3-rule : rdfs2_3_7, rdfs2_3_9, rdfs2_5_7, rdfs2_9_11, rdfs3_5_7, rdfs3_9_11
- 各推論タスクを10種類のデータセットで評価
 - 実世界知識データセット (RK)
 - 反実仮想知識データセット (S・NA・NR・SNA・SNR・GS・GSC・RND)
 - ランダム記号列データセット (NS)
- 6段階のタスクレベル (Lv1 - Lv3, Lv1i - Lv3i) を設定

規則定義提示の条件での推論の評価結果

規則タイプ・タスクレベル別平均F1値

GPT-4o mini

規則タイプ	タスクレベル	データセット					
		RK	SNA	GS	GSC	RND	NS
1-rule	Lv1	0.89	0.88	0.66	0.77	0.87	0.86
	Lv3	0.70	0.71	0.49	0.56	0.65	0.77
2-rule	Lv1	0.92	0.88	0.64	0.73	0.88	0.93
	Lv2	0.83	0.81	0.52	0.61	0.80	0.79
	Lv3	0.66	0.63	0.35	0.44	0.65	0.61
3-rule	Lv1	0.83	0.78	0.50	0.59	0.83	0.84
	Lv2	0.72	0.67	0.40	0.49	0.68	0.63
	Lv3	0.64	0.56	0.30	0.38	0.58	0.56

複雑度の増加に伴いF1値は低下

GS：全ての規則でスコアが大きく低下

GSC：リソース名整形でスコアが向上

スコアの低下率が緩やか（GPT-4o mini：0.30）

RK	実世界知識データセット
GS	RKの全リソースの一括シャッフル
GSC	GSを適用後、リソースのタイプに応じてリソース名を整形

GPT-4o

規則タイプ	タスクレベル	データセット					
		RK	SNA	GS	GSC	RND	NS
1-rule	Lv1	0.95	0.95	0.88	0.91	0.94	0.97
	Lv3	0.94	0.93	0.83	0.91	0.91	0.91
2-rule	Lv1	0.95	0.93	0.88	0.91	0.93	0.95
	Lv2	0.96	0.95	0.83	0.87	0.96	0.97
	Lv3	0.92	0.89	0.79	0.86	0.90	0.91
3-rule	Lv1	0.94	0.95	0.87	0.91	0.93	0.96
	Lv2	0.94	0.91	0.79	0.88	0.94	0.96
	Lv3	0.89	0.86	0.71	0.82	0.88	0.88

規則名提示の条件での推論の評価結果

規則タイプ・タスクレベル別平均F1値（GPT-4o mini）

規則定義提示

規則タイプ	タスクレベル	データセット					
		RK	SNA	GS	GSC	RND	NS
1-rule	Lv1	0.89	0.88	0.66	0.77	0.87	0.86
	Lv3	0.70	0.71	0.49	0.56	0.65	0.77
2-rule	Lv1	0.92	0.88	0.64	0.73	0.88	0.93
	Lv2	0.83	0.81	0.52	0.61	0.80	0.79
	Lv3	0.66	0.63	0.35	0.44	0.65	0.61
3-rule	Lv1	0.83	0.78	0.50	0.59	0.83	0.84
	Lv2	0.72	0.67	0.40	0.49	0.68	0.63
	Lv3	0.64	0.56	0.30	0.38	0.58	0.56

規則名提示

規則タイプ	タスクレベル	データセット					
		RK	SNA	GS	GSC	RND	NS
1-rule	Lv1i	0.68	0.64	0.18	0.21	0.63	0.59
	Lv3i	0.58	0.58	0.16	0.19	0.56	0.47
2-rule	Lv2i	0.45	0.37	0.16	0.20	0.37	0.29
	Lv3i	0.36	0.34	0.16	0.19	0.34	0.22
3-rule	Lv2i	0.32	0.23	0.11	0.12	0.24	0.22
	Lv3i	0.23	0.23	0.12	0.13	0.22	0.13

0.21の性能低下（定義提示：0.64）

0.41の性能低下（定義提示：0.41）

RK	実世界知識データセット
GS	RKの全リソースの一括シャッフル
GSC	GSを適用後、リソースのタイプに応じてリソース名を整形

規則名提示の条件での推論の評価結果

規則タイプ・タスクレベル別平均F1値（GPT-4o）

規則定義提示

規則タイプ	タスクレベル	データセット					
		RK	SNA	GS	GSC	RND	NS
1-rule	Lv1	0.95	0.95	0.88	0.91	0.94	0.97
	Lv3	0.94	0.93	0.83	0.91	0.91	0.91
2-rule	Lv1	0.95	0.93	0.88	0.91	0.93	0.95
	Lv2	0.96	0.95	0.83	0.87	0.96	0.97
	Lv3	0.92	0.89	0.79	0.86	0.90	0.91
3-rule	Lv1	0.94	0.95	0.87	0.91	0.93	0.96
	Lv2	0.94	0.91	0.79	0.88	0.94	0.96
	Lv3	0.89	0.86	0.71	0.82	0.88	0.88

規則名提示

規則タイプ	タスクレベル	データセット					
		RK	SNA	GS	GSC	RND	NS
1-rule	Lv1i	0.91	0.86	0.48	0.68	0.85	0.84
	Lv3i	0.88	0.84	0.45	0.58	0.82	0.81
2-rule	Lv2i	0.91	0.77	0.36	0.55	0.87	0.82
	Lv3i	0.87	0.75	0.33	0.52	0.83	0.80
3-rule	Lv2i	0.70	0.73	0.28	0.49	0.79	0.75
	Lv3i	0.82	0.70	0.27	0.47	0.77	0.76

0.04の性能低下（定義提示：0.95）

0.23の性能低下（定義提示：0.91）

0.44の性能低下（定義提示：0.71）

0.07の性能低下（定義提示：0.82）

RK	実世界知識データセット
GS	RKの全リソースの一括シャッフル
GSC	GSを適用後、リソースのタイプに応じてリソース名を整形

Lv3およびLv3iにおける規則選択能力の評価結果

モデル・規則タイプ別平均F1値

規則定義提示（Lv3）

モデル名	規則タイプ	データセット					
		RK	SNA	GS	GSC	RND	NS
gpt-4o-mini	1-rule	0.84	0.85	0.76	0.77	0.85	0.80
	2-rule	0.89	0.90	0.81	0.82	0.95	0.96
	3-rule	0.82	0.82	0.84	0.85	0.87	0.91
gpt-4o	1-rule	0.98	1.00	0.98	0.99	1.00	0.99
	2-rule	0.99	0.99	0.89	0.91	0.99	1.00
	3-rule	0.97	0.96	0.93	0.96	0.97	0.98

規則名提示（Lv3i）

モデル名	規則タイプ	データセット					
		RK	SNA	GS	GSC	RND	NS
gpt-4o-mini	1-rule	0.20	0.20	0.24	0.24	0.21	0.21
	2-rule	0.46	0.44	0.47	0.46	0.44	0.41
	3-rule	0.65	0.63	0.65	0.65	0.62	0.61
gpt-4o	1-rule	0.58	0.61	0.40	0.40	0.60	0.61
	2-rule	0.59	0.59	0.53	0.54	0.62	0.65
	3-rule	0.66	0.65	0.61	0.63	0.67	0.70

- ・ GPT-4o では、規則結合数の増加に伴い精度が低下
- ・ GPT-4o mini では、1-rule の精度が一番低い

- ・ 両モデルとも Lv3 と比べ大きく精度が低下

RK	実世界知識データセット
GS	RKの全リソースの一括シャッフル
GSC	GSを適用後、リソースのタイプに応じてリソース名を整形

タスクLv3での推論失敗の例

GPT-4o mini での推論失敗の例（rdfs2・RK・Lv3）

項目	内容
前提知識	<code><residence, rdfs:domain, Person></code> <code><Camille_Leblanc-Bazinet, residence, Boulder_Colorado></code>
期待出力	<code><Camille_Leblanc-Bazinet, rdf:type, Person></code>
モデル出力	<code><Camille_Leblanc-Bazinet, rdf:type, Person></code> <code><Boulder_Colorado, rdf:type, Residence></code>

規則	前提	結論
rdfs2	<code><i, rdfs:domain, X>, <a, i, b></code>	<code><a, rdf:type, X></code>
rdfs3	<code><i, rdfs:range, X>, <a, i, b></code>	<code><b, rdf:type, X></code>

原因：`<residence, rdfs:range, Residence>` を補完し、rdfs3 を適用している

考察

- ・ GSが最低精度で、GSC（GSのリソース名整形）で改善した
＞ **語彙的特徴や命名規則**を推論の手がかりとして利用している
- ・ GPT-4o mini での規則の過剰適用は GPT-4o ではほとんど確認されなかった
＞ GPT-4o はタスクの制約（提示された前提知識および規則のみに基づいて推論）に忠実
GPT-4o mini は文脈の整合性や意味的な自然さを優先
＞ **モデルサイズ**に起因する制御能力や構造的知識の保持能力の差が原因である可能性
- ・ 規則名のみを提示した場合（Lv1i～Lv3i）では精度が大幅に低下
＞ 規則の知識の有無に関わらず、**定義の明示**が推論精度に強く寄与している可能性

結論

- ・ 両モデルとも実世界知識のタスクでは実用的な性能を持つ
- ・ 事前学習知識を使って情報を補完する能力がある
 - ＞セマンティックWebのデータの不完全性を考慮すると有用に機能する可能性
- ・ モデル規模・学習データ拡充により精度向上
 - ＞タスクの制約の遵守、言語的パターンへの依存の緩和効果あり
- ・ 純粋な論理推論能力には限界あり

今後の展望

- ・ OWL などより表現力の高い言語での検証
- ・ 規則選択部分に RAG を活用した新たな評価手法の構築
 - ＞規則数が多い OWL では、プロンプトに含まれる規則が入力トークン数を増加させるため
- ・ オープンウェイトLLMでの検証

まとめ

- ・ RDFS推論規則を対象とした推論能力の包括的な評価手法を確立
 - ・ RDFSトリプルを用いた、厳密な評価手法を確立
 - ・ 推論タスクを従来研究から複雑化
 - ・ 適切なRDFS推論規則を選択する能力を評価
- ・ GPT-4o mini と GPT-4o を対象として評価を実施
 - ・ 実世界知識のタスクでは実用的な性能
 - ・ 特に、不完全なセマンティックWebデータにおいて有用に機能する可能性
 - ・ モデル規模・学習データの拡充により精度向上
 - ・ 純粋な論理推論には課題あり
- ・ OWL を対象とした評価、RAG を使った新規評価手法の確立を目指す

FIN

ご清聴ありがとうございました